

2. 연구 동기

주식 시장과 마찬가지로, 비트코인 역시 (뉴스, 시장 심리, 글로벌 거시경제 변수)등에 의해 영향을 받는다. 우리는 이 논문에서 왜 비트코인이 linearity를 가정하면 안 되는지에 대해 서술하고자 한다.

linear regression을 가정하기 위해서, 우리는 기본적으로 5가지 가정을 한다.

1. (선형성) 2.(다중공선성) 3.(외생성) 4.(자기상관성) 5.(등분산성) 추가 데이터가 과연 이 5가지 조건을 엄밀히 만족하는지부터 살펴보자.

3. Data

Variable	Mean	Std	Skewness	Kurtosis	ADF Statistic	p- value	Formula
PriceUSD	0.0022	0.0406	-0.1060	6.2599	-32.8852	0.0000	$\Delta PriceUSD_t = \frac{PriceUSD_t - PriceUSD_{t-1}}{PriceUSD_{t-1}}$
BkCount	147.8582	16.5530	-0.3723	1.1361	-6.4035	0.0000	$BkCount_t$
BkSize	0.0101	0.1437	1.1260	4.2925	-6.6801	0.0000	$\Delta BkSize_t = \frac{BkSize_t - BkSize_{t-1}}{BkSize_{t-1}}$
DiffM	0.0023	0.0171	1.1096	42.8772	-7.9966	0.0000	$\Delta DiffM_t = \frac{DiffM_t - DiffM_{t-1}}{DiffM_{t-1}}$
FeeUSD	3.8228	6.6907	4.0090	20.2875	-3.3593	0.0124	$FeeUSD_t$
Hash_Rate	0.0097	0.1261	0.7776	2.5203	-26.0803	0.0000	$\Delta Hash\_Rate_t = \frac{Hash\_Rate_t - Hash\_Rate_{t-1}}{Hash\_Rate_{t-1}}$
RevUSD	0.0090	0.1294	0.8198	2.8512	-37.6867	0.0000	$\Delta RevUSD_t = \frac{RevUSD_t - RevUSD_{t-1}}{RevUSD_{t-1}}$

Variable	Mean	Std	Skewness	Kurtosis	ADF Statistic	p- value	Formula
TxValAdjUSD	0.0660	0.4274	2.8765	17.7569	-6.8575	0.0000	$\Delta \text{TxValAdjUSD}_t = \frac{\text{TxValAdjUSD}_t - \text{TxValAdjUSD}_{t-1}}{\text{TxValAdjUSD}_{t-1}}$
URTH	0.0003	0.0099	-0.9888	24.6577	-9.4896	0.0000	$\Delta \text{URTH}_t = \frac{\text{URTH}_t - \text{URTH}_{t-1}}{\text{URTH}_{t-1}}$
GSPC	0.0003	0.0105	-0.6172	21.9839	-9.7565	0.0000	$\Delta \text{GSPC}_t = \frac{\text{GSPC}_t - \text{GSPC}_{t-1}}{\text{GSPC}_{t-1}}$
RiskFree	0.0019	0.0275	1.9750	27.2993	-6.2836	0.0000	$\Delta \text{RiskFree}_t = \text{RiskFree}_t - \text{RiskFree}_{t-1}$
OAS	4.1297	1.0263	2.5562	8.7330	-3.4424	0.0096	$\text{OAS}_t$
TenYear	0.0006	0.0286	1.6946	44.9141	-8.0629	0.0000	$\Delta \text{TenYear}_t = \frac{\text{TenYear}_t - \text{TenYear}_{t-1}}{\text{TenYear}_{t-1}}$
TwoYear	0.0017	0.0472	0.9434	13.1693	-24.9820	0.0000	$\Delta \text{TwoYear}_t = \frac{\text{TwoYear}_t - \text{TwoYear}_{t-1}}{\text{TwoYear}_{t-1}}$
VIX	19.5261	8.4034	2.0822	8.4596	-4.1856	0.0007	$\text{VIX}_t$
USDIndex	0.0000	0.0026	0.2479	5.3907	-10.5806	0.0000	$\Delta \text{USDIndex}_t = \frac{\text{USDIndex}_t - \text{USDIndex}_{t-1}}{\text{USDIndex}_{t-1}}$
ExpInflation	0.0003	0.0198	5.7912	210.3612	-12.2697	0.0000	$\Delta \text{ExpInflation}_t = \frac{\text{ExpInflation}_t - \text{ExpInflation}_{t-1}}{\text{ExpInflation}_{t-1}}$
USNewsSent	-0.0432	0.2005	-0.8955	1.1627	-2.8680	0.0492	$\text{USNewsSent}_t$

## 4. Methodology

이 연구는 Bitcoin의 return을 예측하는 것을 목표로 하며, 가격 변수만을 사용할 때와 exogenous variables를 사용할 때 각각 linearity와 nonlinearity의 차이를 비교하고자 한다. 다음 날의 가격 또는 수익률을 예측하는 방식으로 진행되었다.

본 연구에서는 AR, ARIMA, Random Forest (RF), XGBoost 방법을 사용하여 성능을 비교한다.

### 4.1 AR 모델

Autoregression (AR) 모델은 대표적인 linear regression model로, 과거 자기 자신의 값을 이용하여 미래 값을 예측하는 방식이다. 이 모델은 다음과 같이 정의된다:

$$X_{t+1} = \alpha_0 + \sum_{i=1}^p \alpha_i X_{i,t} + \varepsilon_{t+1}$$

여기서  $p = 6$ 을 사용하였다.( $p$ 는 Paye (2012)를 참고하여 설정.)

또한 단일 변수를 사용하는 AR 모델 외에도, 여러 개의 exogenous variables를 포함하는 ARX (Autoregressive with Exogenous Variables) 모델을 적용하였다. ARX 모델은 다음과 같이 정의된다:

$$X_{t+1} = \alpha_0 + \sum_{i=1}^p \alpha_i X_{i,t} + \sum_{i=1}^q \beta_i Y_{i,t} + \varepsilon_{t+1}$$

여기서  $Y_t$ 는 exogenous variables들의 집합이며,  $q$ 는 변수의 수를 나타낸다.  
(exogenous variables는 contemporaneous term만 반영하고, lag term은 주지 않았다.)

### 4.2 ARIMA 모델

ARIMA는 autoregression을 기반으로 differencing과 moving average 요소를 결합한 linear regression model이다. 시계열 데이터가 비정상(non-stationary)일 경우, 차분을 통해 정상성(stationarity)을 확보한 후 모델을 적용한다.

ARIMA 모델은 다음과 같은 수식으로 표현된다:

$$\Delta X_{t+1} = \alpha_0 + \sum_{i=1}^p \alpha_i \Delta X_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_{t+1}$$

여기서  $\Delta X_t = X_t - X_{t-1}$ 는 1차 차분값을 의미하고,  $p$ 는 AR 차수,  $q$ 는 MA 차수를 의미한다.

AR 모델과 마찬가지로, ARIMA에도 exogenous variables를 추가한 확장형인 ARIMAX (ARIMA with Exogenous Variables) 모델을 적용하였다. ARIMAX는 다음과 같이 표현된다:

$$\Delta X_{t+1} = \alpha_0 + \sum_{i=1}^p \alpha_i \Delta X_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \sum_{k=1}^r \gamma_k Y_{k,t} + \varepsilon_{t+1}$$

여기서  $Y_{k,t}$ 는  $k$ 번째 exogenous variable이며,  $r$ 은 전체 변수 수를 의미한다.  
(ARIMAX에서도 exogenous variables는 contemporaneous term만 사용했다.)

#### 4.2.2 비선형 모델

- Random Forest Regressor
- XGBoost Regressor
- LightGBM Regressor

비선형 모델은 다수의 결정 트리를 이용하여 복잡한 비선형 관계를 포착하며, 예측식은 다음과 같이 나타낼 수 있다:

$$\hat{y}_{t+1} = \frac{1}{T} \sum_{j=1}^T f_j(X_t)$$

여기서  $T$ 는 트리의 총 수,  $f_j$ 는  $j$ 번째 트리를 의미한다.

### 4.3 변수 중요도 해석

비선형 모델에서는 예측 결과에 대한 변수 기여도를 분석하기 위해 SHAP (SHapley Additive exPlanations) 값을 이용하였다. SHAP 값은 다음과 같은 선형 가산 모형으로 표현된다:

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i$$

여기서  $\phi_0$ 는 베이스 값,  $\phi_i$ 는 각 변수  $x_i$ 의 기여도를 의미한다.

이를 통해 외생 변수들이 비트코인 가격 예측에 미치는 상대적 중요성을 평가하였다.

### 4.4 평가 지표

모델 성능은 다음과 같은 지표를 통해 평가하였다:

- **RMSE (Root Mean Squared Error):** 평균 제곱 오차의 제곱근
- **MAPE (Mean Absolute Percentage Error):** 백분율 기준 절대 오차
- **$R^2$  (결정계수):** 설명력
- **MDA (Mean Directional Accuracy):** 상승/하락 방향성 예측 정확도

RMSE는 다음과 같이 정의된다:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y_t - \hat{y}_t)^2}$$

MAPE는 다음과 같이 정의된다:

$$\text{MAPE} = \frac{100}{N} \sum_{t=1}^N \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

$R^2$ 는 다음과 같이 정의된다:

$$R^2 = 1 - \frac{\sum_{t=1}^N (y_t - \hat{y}_t)^2}{\sum_{t=1}^N (y_t - \bar{y})^2}$$

여기서  $\mathbf{1}(\cdot)$ 은 인디케이터 함수이다.

#### 4.1 ar model

모든 모델 학습은 시계열 순서를 고려한 **Rolling Forecasting Window** 방식을 사용하였다. 구체적으로, 30일간의 학습 데이터를 이용하여 다음 1일을 예측하는 구조를 반복하였다. 학습 및 검증 단계에서는 다음의 과정을 따른다:

- 학습 구간: 30일
- 예측 구간: 다음 1일
- 이동 간격: 1일
- Time lag: 6일

하이퍼파라미터 튜닝은 시계열 특성을 반영하기 위해 TimeSeriesSplit을 사용하고, 각 모델의 최적 파라미터는 Grid Search를 통해 탐색하였다.